



本科毕业设计(论文)

题目: 基于生成对抗网络的

ECT 图像重建算法

学 院: 信息科学学院

专 业: 计算机科学与技术

班 级: 1950802

学 号: 195080424

学生姓名：杨苏恒

指导教师: 徐昇 职称: 副教授

二〇二三年五月十一日

基于生成对抗神经网络的 ECT 图像重建算法

摘要

电容层析成像(ECT)技术,具有实时性高、非侵入式、成本低的优势,被广泛应用于多相流的流体检测过程。电容层析成像技术通过检测管道内部电容值的变化,对容器内部流体进行可视化重建。由于 ECT 系统本身具有的软场特性,在进行可视化重建时,不可避免的对结果产生影响。

传统算法与先前基于机器学习的算法图像重构成像由于 ECT 的特性,效果差、分辨率低,边缘不清晰。且与 ECT 传感器高度耦合,难以迁移、复用。

为了减轻 ECT 特性带来的病态化问题,本文采用了生成对抗网络(GAN)作为解决办法。本文尝试运用了多种类 U-Net 结构作为生成器的 GAN;在 ECT 图像重建方面,验证了 GAN 的可行性。

本文提出的 Link2Net 结构,在 SSIM 与 MAE 的评价指标上,Link2Net 相较于传统方法,分别有 35.22%、91.95%的提升;相较于作为基准线的 Pix2Pix,减少 81.27%运算量的同时,分别有 2.66%、48.44%的提升。创新点如下:

(1) Link2Net 使用 Res2Net 中的残差网络改进了 LinkNet 的编码器。具有多层次,可快速调整网络规模的优点,相比于 LinkNet 减少了计算量,增加模型精度。

(2) Link2Net 在编码器与解码器之间加入了特征提取层,提高精度;能够更好的提取图像特征,使图像更贴近现实情况,边界有更清晰的显示,避免丢失边界信息,产生图像畸变。

(3) 将算法与传统算法相结合,具有高度可移植性,与 ECT 检测电路硬件解耦合。可以根据需求替换不同的 ECT 传感器与基础重建算法。

关键词: 生成对抗网络; 电容层析成像; Res2Net; Encoder-Decoder

ECT Image Reconstruction Algorithm Based on Generative Adversarial Neural Network

ABSTRACT

Electric capacitance tomography (ECT) technology has the advantages of high real-time performance, non-invasiveness, and low cost, and is widely used in the fluid detection process of multiphase flow. Electrical capacitance tomography technology can visually reconstruct the fluid inside the container by detecting the change of the capacitance value inside the pipeline. Due to the soft-field characteristics of the ECT system itself, it will inevitably affect the results when visual reconstruction is performed.

Due to the characteristics of ECT, traditional algorithms and previous machine learning-based image reconstruction imaging have poor effects, low resolution, and unclear edges. Moreover, it is highly coupled with ECT sensors, making it difficult to migrate and reuse. To alleviate the ill-conditioned problem caused by ECT properties, this paper adopts generative adversarial network (GAN) as a solution. This article tries to use a variety of U-Net structures as the generator's GAN; in terms of ECT image reconstruction, the feasibility of GAN is verified.

The Link2Net structure proposed in this paper, in the evaluation indicators of SSIM and MAE, Link2Net has an improvement of 35.22% and 91.95% respectively compared with the traditional method; There are 2.66% and 48.44% improvements.

The innovations are as follows:

(1) Link2Net uses the residual network in Res2Net to improve the encoder of LinkNet. It has the advantages of multi-level and can quickly adjust the network scale. Compared with LinkNet, it reduces the amount of calculation and increases the accuracy of the model.

(2) Link2Net adds a feature extraction layer between the encoder and the decoder to improve the accuracy; it can better extract image features, make the image

closer to reality, and display the boundary more clearly, avoid losing boundary information, and generate images distortion.

(3) Combining the algorithm with the traditional algorithm, it is highly portable and decoupled from the hardware of the ECT detection circuit. Different ECT sensors and base reconstruction algorithms can be replaced according to requirements.

Key words: GAN; Electric capacitance tomography; Res2Net; Encoder-Decoder

目 录

1	绪论.....	- 1 -
1.1	研究背景与意义.....	- 1 -
1.2	国内外研究现状.....	- 1 -
1.2.1	ECT 成像技术重建算法研究概况	- 1 -
1.2.2	其他相关成像技术重建算法研究概况.....	- 3 -
1.2.3	相关成像技术重建算法总结与分析.....	- 3 -
1.3	本文的主要研究内容	- 3 -
1.4	本文组织结构.....	- 4 -
2	相关技术.....	- 6 -
2.1	生成对抗网络 (GAN)	- 6 -
2.2	Pix2Pix	- 6 -
2.3	ResNet.....	- 7 -
2.4	LinkNet.....	- 8 -
2.5	Res2Net.....	- 10 -
2.6	SENet	- 11 -
2.7	本章小结.....	- 11 -
3	模型的设计与训练.....	- 12 -
3.1	数据增强.....	- 12 -
3.2	设计思想	- 12 -
3.2.1	损失函数.....	- 12 -
3.2.2	生成器设计.....	- 13 -
3.2.3	特征提取层.....	- 14 -
3.3	网络结构.....	- 14 -
3.4	本章小结.....	- 16 -
4	试验与结果分析.....	- 17 -
4.1	试验结果.....	- 17 -
4.2	测试结果评价.....	- 17 -
4.3	本章小结.....	- 18 -
5	总结与展望.....	- 19 -
5.1	总结.....	- 19 -
5.2	展望.....	- 19 -

1 绪论

1.1 研究背景与意义

过程层析成像(process tomography, PT)技术是一种以非侵入性的方式测量感兴趣区域的过程化参数并获得容器反应过程或管道内部流动特征的技术^[1], PT 技术涉及到多个应用领域的研究,例如工业上的多相流参数监测、石油勘探、无损检测等,医学上的人体肺部换气成像影像诊断、脑部成像等。

电容层析成像技术(ECT)属于 PT 技术的一种,是通过生成横截面图像来可视化介电多相流过程,主要应用于工业中循环流化床的气固流动检测、水平管道中油/水两相流的检测和火焰燃烧检测等^[2]。传统的 ECT 系统主要包含三个部分: ECT 传感器、电容测量与数据采集电路、成像计算机。基于电容测量电路测量非冗余电极组合中所有可能的电容数据^[3],并可以通过一定的算法重建介电常数分布。

相的概念通常是指在某系统中具有相同性质的部分,即状态以及物理化学性质完全相同的部分称为相。固相、液相、气相分别为相的三种不同表现形式,又根据系统内相的数量将系统分为单相流与多相流,单相流即只有一种相存在的系统,多相流即混合了两相或以上的系统,在各相之间存在较为明确的界面。由于现代工业环境复杂,因此在现代工业中几乎不存在单相流动情况,针对工业检测系统,须同时考虑两个或两个以上混合相的流动。

1980 年后期,为了对工业管道流动参数进行检测,ECT 技术应运而生,经过长达几十年的发展,如今已在输油管道中的油气两相流系统、气力输送中的气固两相流等流型可视化监测中得到应用^[4]。在 ECT 系统中,管壁侧分布有金属电极板,管道内含有待检测的两相或多相介质的流动体系,流动体系发生变化时将会产生相应的介电常数变化,此时只要通过测量电极对之间的电容值,便可以了解到封闭管道内的流型以及运动状态,获得二维或三维的可视化图像信息。相对于其他检测技术,ECT 技术安全性能好、非侵入式、适用范围广,通过 ECT 技术进行研究可以给其他复杂过程检测技术提供基础和借鉴。

1.2 国内外研究现状

1.2.1 ECT 成像技术重建算法研究概况

ECT 技术的图像重建实质是对逆问题的求解,即根据电容传感器测量的电容

值求解敏感场内介电常数的分布。由于测量的独立投影数据远远少于图像的像素点，导致其解不唯一，属于欠定性问题。

传统的 ECT 重建算法，包括非迭代算法与迭代算法，大都是基于线性模型寻求问题的最优解。但是当数据量过大，成像目标复杂时候，这些方法的运算成本会大大增高；而基于非线性模型的重建算法，图像重建的速度非常慢，无法满足实效性的要求。

非迭代算法典型算法的有线性反投影（LBP）^[5]、Tikhonov 正则化^[6]。LBP 是一种运用较为广泛的算法。LBP 算法通过将转置后的灵敏度场矩阵作为逆矩阵来求解，进而获得近似解。由于 ECT 的软场特性，往往 LBP 算法的结果不尽人意。Tikhonov 正则化算法，利用最小二乘法和稳定函数，把正则解作为近似解，尝试缓解 ECT 系统中存在的病态问题；该算法求解快，但是容易丢失边缘信息。

迭代算法典型算法的有 Landweber^[7]等。Landweber 法的原理本质上就是通过正则，残差平方和作为目标函数，反复迭代 LBP 算法，使其贴合目标值。缺点是在一段时间迭代后无法收敛，在超过一段时期之后，解会发散。

近年来，人工智能算法和机器学习理论蓬勃发展，已经有了若干种基于深度学习的方法拓展到了解决这类非线性的逆问题上。基于神经网络的学习算法在对非线性信号处理中展现了良好的成像效果。2012 年，Li J W 等提出了一种基于径向基函数(RBF)神经网络的图像重构方法^[8]，通过仿真软件获得 ECT 训练数据。该模型通过直接采集传感器的信号进行重建并相较于原有方法速度更快，精度更高；但是产生的重建图片清晰度并不理想。2018 年，ZHENG J 等提出了一种自动编码神经网络来求解 ECT 的图像重建问题^[9]，共有 40000 对样本训练和测试数据集，图像重建效果较好。2019 年，CHEN E 等在此基础上使用模块化深度神经网络进行重建^[10]。同年，P N Darama 等人试用 K-means 聚类算法对扇形灵敏度矩阵计算，对包含像素点的区域进行聚类，减小了 ECT 问题的软场效应与伪影的产生^[11]。

2020 年，鞠冲针对 ECT 成像精度不高的问题，提出了基于对抗生成网络的 ECT 图像重建^[12]，虽然成像效果不理想，但是这是一次成功的将传统 ECT 重建算法产生的图像进行二次重建的尝试。

2021 年，DEABES W 等提出了一种基于长短期记忆(LSTM)深度网络的 ECT 重构算法^[13]，简称 LSTM-IR 算法，通过创建的 16 万对大规模仿真数据集进行训练和测试，证明了 LSTM-IR 方法可以更快速，精准的创建 ECT 图像。但是该方法需要极大量的数据集进行训练，有一定在不同 ECT 探测器上复用难度。

1.2.2 其他相关成像技术重建算法研究概况

电学层析成像(ET)存在三种基本形式，电容层析成像（Electrical Capacitance Tomography, ECT）、电阻层析成像（Electrical Resistance Tomography, ERT）和电磁层析成像（Electromagnetic Tomography, EMT）。这三种形式的成像方法后的重建算法类似，有一定可相互借鉴之处。

2022 年，韩旭发表的基于 GAN 的 ECT/ERT 双模态传感器数据融合算法研究^[14]，将生成对抗网络(GAN)与自编码神经网络结合，解决了单独使用 ECT 或 ERT 技术数据采集效率差，精度低的问题，也验证了 GAN 运用于 ECT 技术的可行性。

同年，张悦等发表的利用改进 SRGAN 对 CT 图像增强应用研究^[15]，将注意力机制引入生成器，使得图像在结构相似度(SSIM)，峰值信噪比(PSNR)等方面取得较好结果。并增强了边缘纹理，使得生成图像更加真实。

1.2.3 相关成像技术重建算法总结与分析

传统方法的线性成像方法效率高，但是成像效果差；非线性方法成像效率低下。

现有的基于机器学习的 ECT 图像重建学习方法基本与 ECT 传感器或数据采集网络深度耦合，难以迁移，复用性差。普遍来说，重建的图像不清晰，重建困难是由于 ECT 网络特性导致的。故此，大部分对于 ECT 图像重建的研究主要都是基于硬件对于现有网络进行的改动。除此以外，现有模型对于 ECT 的重建算法复杂度高，速率较慢，难以满足实时性要求。

基于 GAN 的 ECT/ERT 双模态传感器融合研究是将多种传感器数据结合并产生精度更高的方式，但同时也增大了应用部署成本。而基于 SRGAN 的研究，是将 GAN 网络直接运用于已经重建过的图像，具有很大的参考价值。

从此角度出发，根据传统算法或者基于机器学习的 ECT 重建算法先进行一次图像重建，再运用模型对该图像进行二次重建。一方面可以继承初次重建算法的优点，另一方面可以赋予二次重建算法模型，可复用，可移植，可替换的优点。这样，二次重建算法可以与 ECT 硬件网络解耦合，只关注二次重建后的图片产生的准确度与精确性。

1.3 本文的主要研究内容

本文主要研究内容主要分为以下三点：

1. 将 Linknet 与 Res2Net 相结合，提出 Link2Net 网络结构。使用由若干层 Res2Net 组成的 Encoder 取代 LinkNet 中原有的 Encoder。Link2Net 能够在有限残

差块中构建了分层的残差连接，可以更好的利用多尺度特征，间接扩大感受野。除此以外，Link2Net 引入了 **scale** 的概念，并在 **scale** 这一维度上进行分层的残差连接，可以更好的表示多尺度特征。

2. 在 Encoder 与 Decoder 中加入了特征提取层，可以增加信息流动的路径，使网络能够更好地利用图像中的特征。

3. 本文的 ECT 图像重建算法为二次图像重建算法，相比传统算法可移植、可替换，高度与硬件解耦合。

1.4 本文组织结构

第一章，绪论。简要介绍 ECT 的优点和图像重建算法对于 ECT 的重要性，分析了国内外相关技术的发展近况，分析了相关技术的优缺点。

第二章，相关研究。介绍了与本文提出的模型相关的研究，并简要阐述研究内容与核心思想。

第三章，模型的设计与训练。详细介绍了数据集预处理，模型设计思想，模型结构组成。

第四章，试验与试验效果比较。从结果上和客观评价标准上，横向比较了各个模型的运行结果。

第五章，总结与展望。总结了本文重建算法模型的优点以及应用场景，概括了本文研究的不足之处以及可行的改进方法。

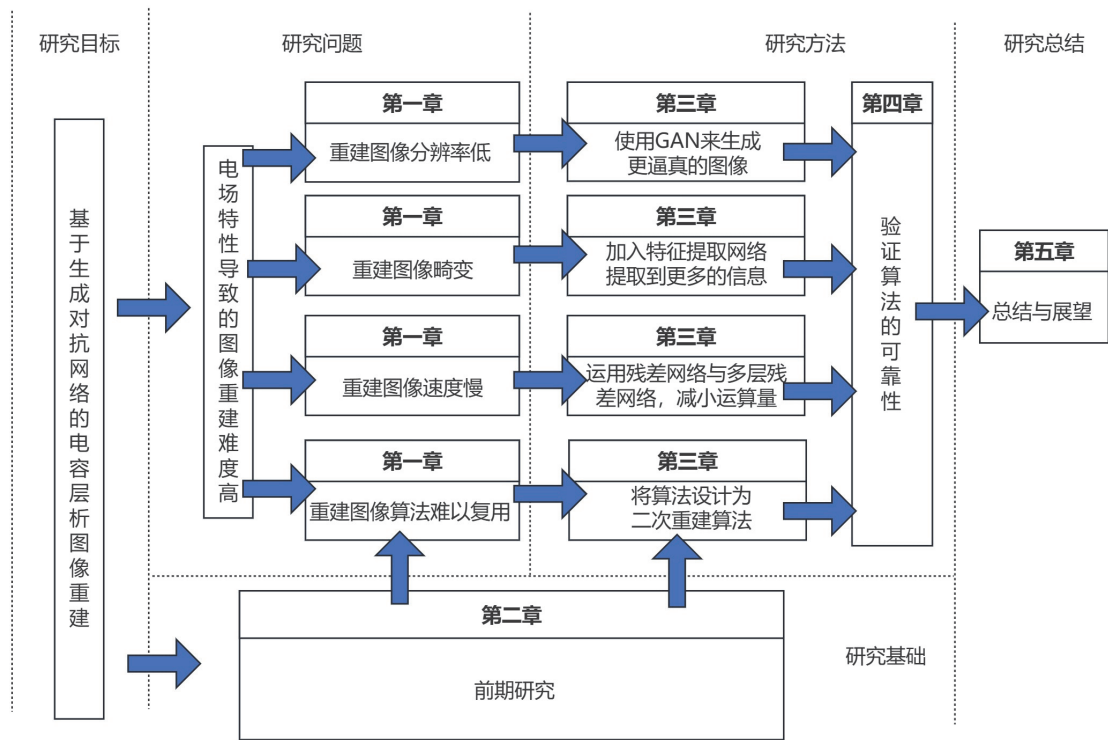


图 1.4.1 本文组织示意图

Figure 1.4.1 Schematic diagram of the organization of this paper

2 相关技术

2.1 生成对抗网络(GAN)

GAN^[16]是 Generative Adversarial Nets 的缩写，是一种生成模型的框架。它通过对抗性训练的方式同时训练两个模型：一个生成模型和一个判别模型。生成模型用于捕捉数据分布，而判别模型则用于估计样本来自于训练数据还是生成模型。这个框架的训练过程可以被看作是一个最小最大化的二人博弈，其中生成器试图欺骗判别器，而判别器则试图识别出真实样本和生成样本之间的区别。

最大最小化二人博弈的数学表达如公式(2.2.1)所示：

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log (1 - D(G(z)))] \quad (2.2.1)$$

对于给定的 G，最佳的鉴别器的数学表达如公式(2.1.2)所示：

$$D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \quad (2.1.2)$$

其中 p_{data} 表示真实数据分布, p_g 表示生成器产生的数据分布。

所以，在理想情况下，当 $D_G^*(x) = \frac{1}{2}$ 是，代表生成器已经达到最佳状态，鉴别器无法检测出生成器产生的结果与真实结果的差异。

2.2 Pix2Pix

Pix2Pix^[17]是一种基于条件生成对抗网络的图像到图像翻译方法。它可以将一种类型的图像转换为另一种类型的图像，例如将线条图转换为真实的照片，或者将黑白照片转换为彩色照片。这种方法不仅可以学习输入和输出之间的映射关系，还可以学习一个损失函数来训练这个映射。因此，它可以应用于许多传统上需要不同损失函数的问题，并且已经在许多领域得到了成功应用。

Pix2Pix 采用了基于 U-Net 的生成器。U-Net 是一种常用于图像分割任务的 CNN 架构，它具有对称的编码器和解码器结构，并且在解码器中使用了跳跃连接（skip connections）来帮助保留更多的空间信息。通过编码器与解码器，Pix2Pix 实现了从图像到图像的转换。

Pix2Pix 采用了 PatchGAN 作为鉴别器。PatchGAN 是一种基于 CNN 的判别器，

它将输入图像分成许多重叠的小块（patch），并对每个小块输出一个二进制值，表示该小块是否为真实图像。相比于全局判别器，PatchGAN 具有更少的参数、更快的运行速度，并且可以处理任意大小的图像。

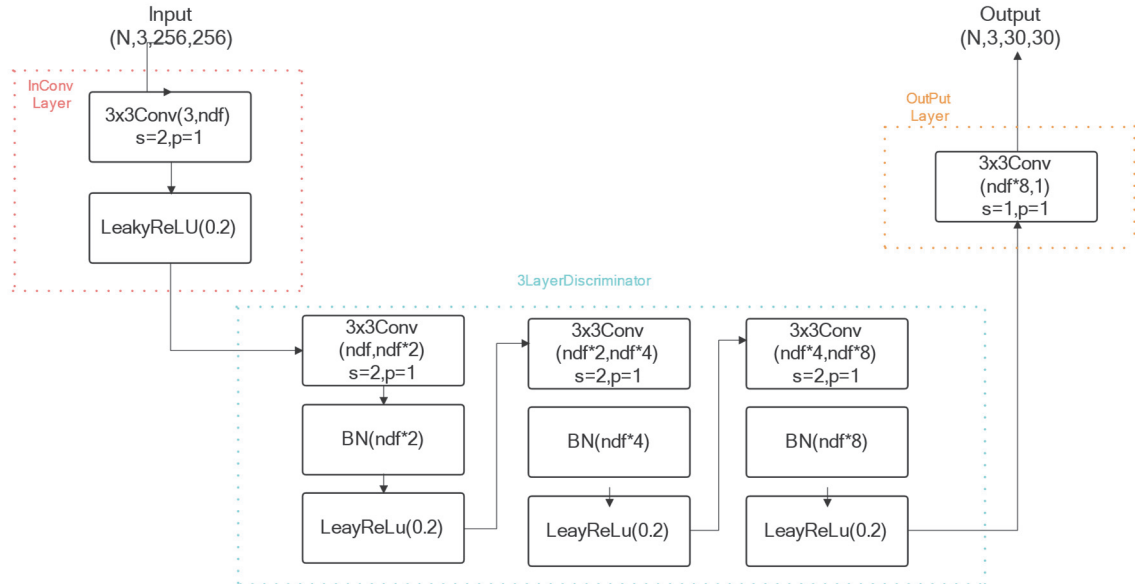


图 2.2.1 具有三层特征提取网络的 PatchGAN 结构图

Figure 2.2.1 PatchGAN structure diagram with three-layer feature extraction network

2.3 ResNet

ResNet^[18]是一种深度残差网络，它通过引入残差连接来解决深度神经网络中的梯度消失问题，其核心思想是将层次结构转化为学习输入与输出之间的残差函数，而不是学习无参考函数（unreferenced functions）。这个框架使得更深的网络可以更容易地优化，并且可以在不牺牲准确性或复杂性的情况下获得更高的深度。

其中，最具特色的是残差组件。残差组件通过显式地将层次结构转化为学习输入与输出之间的残差函数，提高了网络的泛化能力、缓解了梯度消失问题、提高了训练速度。

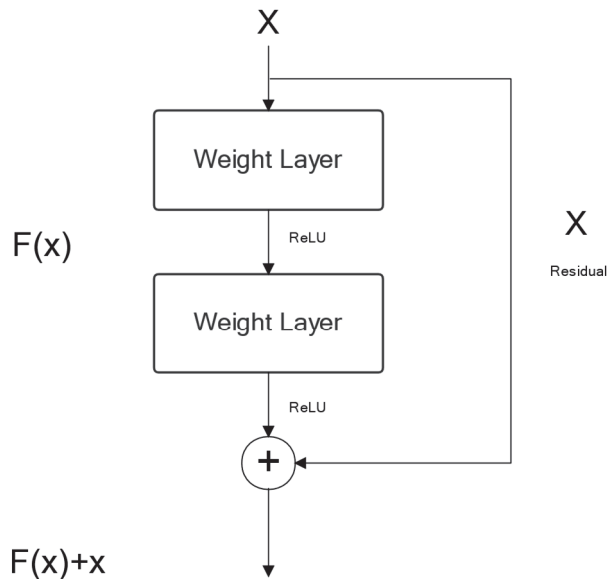


图 2.3.1 ResBlock 残差块结构示意图

Figure 2.3.1 Schematic diagram of ResBlock residual block structure

跨越连接将输入 x 直接添加到 $F(x)$ 的输出中。当输入和输出具有相同的维度时，跨越连接执行恒等映射；当输入和输出具有不同的维度时，跨越连接通过 1×1 卷积来匹配维度。

具体来说，每个残差块都由两个卷积层和一个跳跃连接组成。第一个卷积层用于降低特征图的大小和数量；第二个卷积层用于恢复特征图的大小和数量，并且在这两个卷积层之间添加了批量归一化（batch normalization）和 ReLU 激活函数。跳跃连接将输入直接添加到输出上，使得网络可以学习残差函数而不是完整的映射函数。这样可以避免梯度消失或梯度爆炸，并且使得网络更容易训练。

此外，ResNet 引入了 Bottleneck 这一概念，bottleneck 残差块由三个卷积层组成：一个 1×1 卷积层、一个 3×3 卷积层和另一个 1×1 卷积层。其中第一个和第三个卷积层都是 1×1 大小的，用于降低和恢复特征图的维度；而中间的 3×3 卷积层则是瓶颈，它具有较小的输入/输出维度。这种设计可以大大减少网络中参数数量和计算量，并且在保持准确性方面表现良好。

2.4 LinkNet

LinkNet^[19]是一种用于图像分割的深度卷积神经网络,旨在解决现有图像分割网络在实时性和准确性之间的平衡问题。LinkNet 的 Encoder 与 Decoder 通过残差组件相连，原文称作 Residual Connection，取代了 UNet 中对应的 Skip Connection，

可以帮助网络更好地学习图像特征，并且可以缓解梯度消失问题，同时减小了计算量。

LinkNet 通过在特征提取网络中使用 ResNet 的 Bottleneck，极大程度上降低了计算量。通过这些技术，LinkNet 可以在保持高准确性的同时实现实时图像分割。

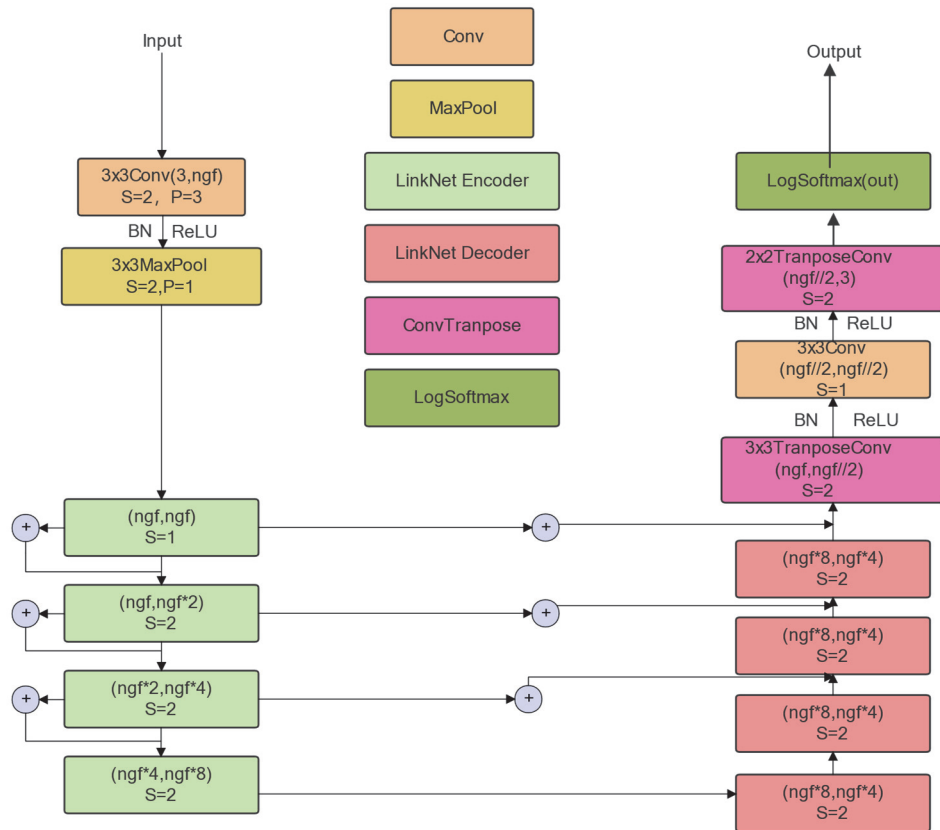


图 2.4.1 LinkNet 总体结构图

Figure 2.4.1 LinkNet overall structure diagram

具体来说，Encoder 由四个 Encoder Block 组成，每个 Block 包含两个 Convolutional Module。每个 Convolutional Module 由一个 3x3 的卷积层、一个 Batch Normalization 层和一个 ReLU 激活函数层组成。在每个 Block 之间，还有一个 2x2 的最大池化层，用于将特征图下采样到原来的 1/2 大小。此外，在第一个 Block 之前还有一个 7x7 的卷积层，用于对输入图像进行初步处理。Decoder 由四个 Decoder Block 组成，每个 Block 包含两个 Convolutional Module 和一个 UpSampling Module。每个 Convolutional Module 与 Encoder Block 中的相应模块相同，由一个 3x3 的卷积层、一个 Batch Normalization 层和一个 ReLU 激活函数

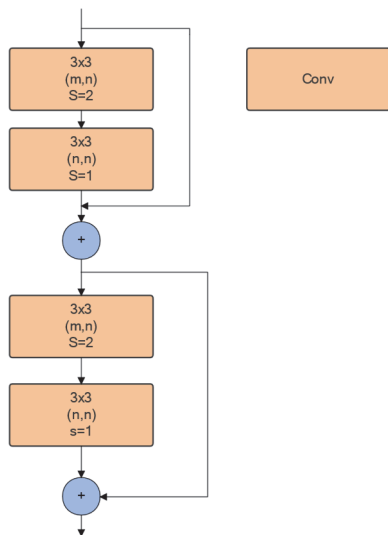


图 2. 4. 1 LinkNetEncoder 结构示意图

Figure 2.4.1 Schematic diagram of LinkNetEncoder structure

总的来说，LinkNet 的 Encoder 采用了一种浅而宽的结构设计层组成，Decoder 采用了一种深而窄的结构设计，可以在保持高准确性的同时实现较快的处理速度。

2.5 Res2Net

Res2Net^[20]是 ResNet 原作者对 ResNet 做出的改进。

相较于 ResNet,Res2Net 在残差块内引入了新的纬度—scale, 并在这个纬度上建立分层连接。这样可以更好的表示多尺度特征。

如图所示，Res2Net Bottleneck 包含了一个 1x1 的卷积用于对输入数据升纬，若干个 3x3 卷积用于分层提取输入特征，最后一个 1x1 的卷积用于将输入数据调整至输出所需要的通道数。

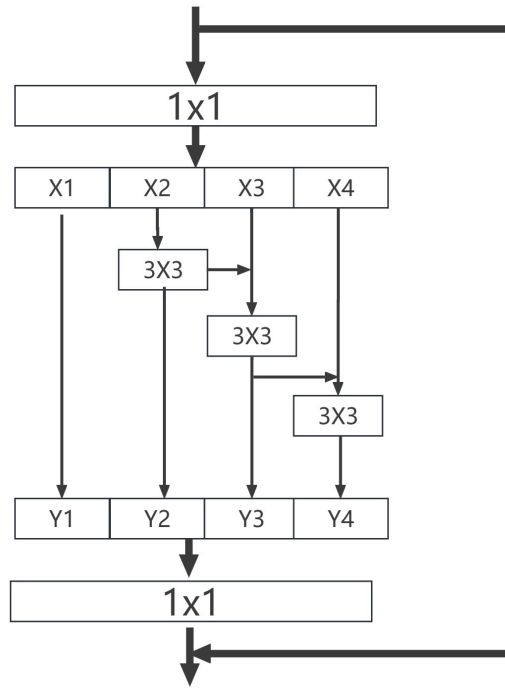


图 2.5.1 Res2NetBottleNeck 结构示意图, scale=4

Figure 2.5.1 Schematic diagram of Res2NetBottleNeck structure, scale=4

2.6 SENet

SENet^[21](Squeeze-and-Excitation)是一种卷积神经网络架构，其中包含 Squeeze-and-Excitation (SE) 块。SE 块通过自适应地重新校准通道特征响应来增强卷积神经网络的表现。这种架构可以在不同的数据集上实现非常有效的泛化，并且在轻微增加计算成本的情况下。

SE 块由两个主要部分组成：**squeeze** 操作和 **excitation** 操作。**squeeze** 操作通过全局平均池化来压缩每个通道的特征图，并将其转换为一个小向量。然后，**excitation** 操作通过使用两个完全连接的层来学习如何重新校准每个通道的特征图。这些层使用 **sigmoid** 函数来生成通道加权系数，这些系数用于重新加权特征图中的每个通道，这些系数用于重新加权特征图中的每个通道。

2.7 本章小结

本章首先分别介绍了生成对抗网络、Pix2Pix 这两个基石；包含了非监督网络工作原理与如何实现图像到图像的转换。然后分别介绍了 ResNet, LinkNet 与 Res2Net 这几个先进的改进算法并说明其优势。最后介绍了 SE 模块，是一种通用的优化模块。

3 模型的设计与训练

3.1 数据增强

如果一个模型能够在多种情况下都能表现良好，则称该模型具有鲁棒性。增强模型的鲁棒性的方法之一就是扩大数据集，避免对训练集过拟合。GAN 由于自身无监督训练特性，极其容易过拟合。数据增强是扩大训练数据集的一种方式。随机剪裁，随机旋转，水平或数值反转，色彩抖动，高斯噪声为几种常见的数据增强方式。

ECT 的扫描成像由于使用电极对，扫描图像通常为中心对称图形。鉴于此种特性，本文采用的增强方法为随机旋转，0、90、180、270 度；每一个训练周期(epoch)的旋转角度均随机。

3.2 设计思想

3.2.1 损失函数

在 Pix2Pix 原论文中，使用了 PatchGAN 与 L1 范式(MAE)对于生成器结果的评价的加权和作为评价指标。

L1，即 MAE（Mean Absolute Error），是一种用于衡量模型预测误差的度量方法，通常用于回归问题中。当将 MAE 作为损失函数（Loss）时，它的作用是用于指导模型优化，使得模型的预测结果尽可能地接近真实值。当将 MAE 作为损失函数时，模型的目标是最小化 MAE。这意味着模型会试图使其预测值与真实值之间的差异尽可能小。因此，MAE 可以被视为衡量模型的精度的度量，因为它将模型的预测误差与真实值的大小联系起来。相比于其他回归损失函数，MAE 的一个优点是它对异常值的鲁棒性较高：在图像转换任务中，由于输入图像的各种变化，很容易出现异常情况。由于 MAE 对于输出图像中每个像素的差异给出了同等的权重，这有助于避免对于图像中某些区域的过度关注，而使得整个图像的质量更为均衡。

MAE 在 Pix2Pix 网络中作为损失函数的作用是衡量模型输出图像与真实目标图像之间的差异，并指导模型优化，使得输出图像尽可能地接近真实目标图像。

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.2.1.1)$$

本文采用了 PatchGAN 与混合评价标准的评价加权和作为评价指标。在混合评价指标包含了 L1 范式与 SSIM 对于结果的评价。

$$SSIM(x,y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (3.2.1.2)$$

其中 C_1C_2 为常数；按照经验，通常取值为 $1 * 10^{-4}$ 与 $9 * 10^{-4}$

与传统的均方误差（MSE）和平均绝对误差（MAE）等损失函数相比，SSIM 在衡量图像质量时考虑了图像结构信息。这意味着，SSIM 可以更好地保留图像的纹理、边缘和细节等信息，从而产生更真实的图像。SSIM 是基于人类视觉感知的模型，因此更能够反映人类视觉对于图像质量的评价。相比于其他损失函数，SSIM 在衡量图像质量时更接近人类视觉感知，从而可以得到更自然、更真实的图像。

当 SSIM 可以与其他损失函数一起使用，作为 GAN 中的辅助损失函数时，可以帮助生成器更好地保留图像的结构和纹理信息，同时抑制 GAN 中的模式崩塌和退化问题。

将 SSIM 与 L1 的加权和作为损失函数有以下优点：

1.更好地保留图像细节：L1 损失能够有效地降低图像的整体像素误差，但是却不太能够保留图像细节信息。而 SSIM 指标则能够更好地度量图像的结构相似性，能够更好地保留图像的细节和纹理信息。将两个指标加权求和可以在保留图像细节的同时减小图像像素误差。

2.更好地抑制伪影和模糊：Pix2Pix 网络在训练过程中，容易出现伪影和模糊的情况。由于 L1 损失无法很好地区分边缘和平滑区域，容易导致图像出现伪影，而 SSIM 指标能够更好地区分边缘和平滑区域，能够减少伪影的出现。

3.2.2 生成器设计

生成器为本文提出的 Link2Net。

Link2Net 相对于 UNet 而言，具有更高的生成质量。Link2Net 使用了基于 Res2Net 的编码器来提取特征，这使得它可以更好地捕捉图像中的高层次语义信息。此外，Link2Net 还使用了多个分支和中间输出，这可以帮助生成器更好地控制生成的图像的细节和纹理。除此之外，Link2Net 具有更高的计算效率：将原有的特征拼接(Skip connection)改为残差网络构成的残差连接(Residual Connections)，采用了 shortcut 连接和像素级别的跳跃连接，这使得 Link2Net 在保持精度的情况下，可以使用更少的参数和计算资源。

相比于 Linknet,Link2net 在编码器中的残差连接是分层的、多尺度的，可以更

好的提取图像的特征。Link2Net 的编码器采用 Res2Net 进行特征提取，Res2Net 在 ResNet 的基础上引入了多组并行的残差分支，可以将特征空间的维度进一步扩展，从而提升了网络的特征表示能力。这些并行的残差分支可以捕捉不同的特征尺度和语义信息，通过组合这些信息可以生成更具有代表性的特征。除此以外，Link2Net 相比 LinkNet 具有更高的模型效率，通过增加网络的宽度和深度。尽管 ResNet 可以通过大量堆叠的方式来提高模型的性能，但是这样会增加模型的计算量和参数量，导致模型变得笨重。而 Res2Net 通过并行连接多个子网络，在完全不增加参数量与计算量的情况下提高了网络的表现。且 Link2Net 的网络结构比 LinkNet 更加灵活，可以通过改变 scale 与通道数来改变模型的性能。因此可以很容易地将 Res2Net 应用于不同的任务和场景，几乎不需要修改代码就可以实现推理速度与推理精度的平衡。

3.2.3 特征提取层

Link2Net 中的特征提取层是仿照 InceptionV3 的结构构建而成，采用了多个 1x1 卷积核的组合方式，通过降低输入通道数来减少计算量，从而达到了更小的模型参数，提高了模型的效率。通过增加网络的深度，使得模型的表达能力更加强大，可以更好地提取输入图像的特征，从而提高模型的准确率

3.3 网络结构

Link2Net 的编码器由四个 Link2Net Encoder 模块组成，而一个 Link2Net Encoder 又由若干个 Res2Net Bottleneck 模块组成。

在本文中，Res2Net Bottleneck 还包含了一个 SE 模块。通过串联 SE 模块与 Bottleneck 中的模块，可以更提取通道间关系，增强有效特征。本文的 SE 模块由平均池化，输入为 channel，输出为 channel//reduction 的 1x1 卷积层，ReLU 激活层，输入为 channel//reduction，输出为 channel 的 1x1 卷积层，一个 Sigmoid 层构成。

在 Link2Net 的一个 Encoder 中，第一个 Res2Net Bottleneck 负责进行下采样，利用卷积神经网络提取特征。其余若干个 Res2Net Bottleneck 的通道数不变，作为特征提取网络存在。




图 3.3.1 Link2Net Encoder 结构示意图

Figure 3.3.1 Schematic diagram of Link2Net Encoder structure

一般来说，Link2Net Encoder 中的 Bottleneck 数量按照 小模型 3, 4, 6, 3 大模型 3, 4, 23, 3 来排列。这样的数量对应着 ResNet50 与 ResNet101 中的特征提取网络安排。




图 3.3.2 Link2Net Decoder 结构示意图

Figure 3.3.2 Schematic diagram of Link2Net Decoder structure

Link2Net 的编码器由四个 Link2Net Decoder 模块组成，Link2Net 的解码器与 LinkNet 类似，都是由一个 1x1 卷积层负责降维，一个 3x3 转置卷积层负责将低分辨率特征图转化为高分辨率特征图，实现特征的细化，最后再由一个 1x1 卷积层负责调整通道数，达到输出要求。

Link2Net 的特征提取层由若干个 Link2NetBlock 组成。一个 Link2NetBlock 分为三层：

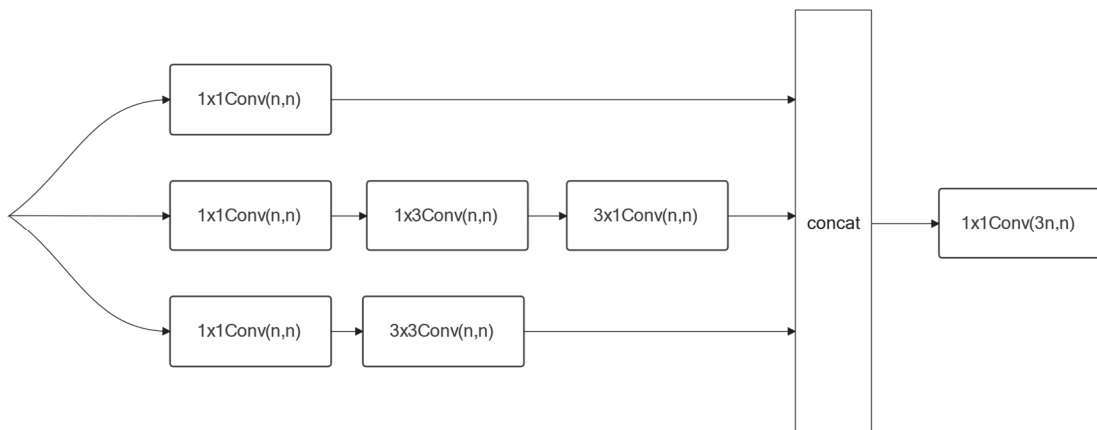


图 3.3.3 Link2NetBlock 结构示意图

Figure 3.3.3 Schematic diagram of Link2NetBlock structure

第一层是 1×1 卷积层，第二层由一个 1×1 卷积层与 3×3 卷积层构成，第三层由一个 1×1 卷积层， 1×3 卷积层， 3×1 卷积层构成，每一个卷积层后都跟有一个 BN 批归一层与一个 Relu 层。最后拼接这三层的结果，并通过一个 1×1 的卷积层将这三层的结果改为需要的通道数。

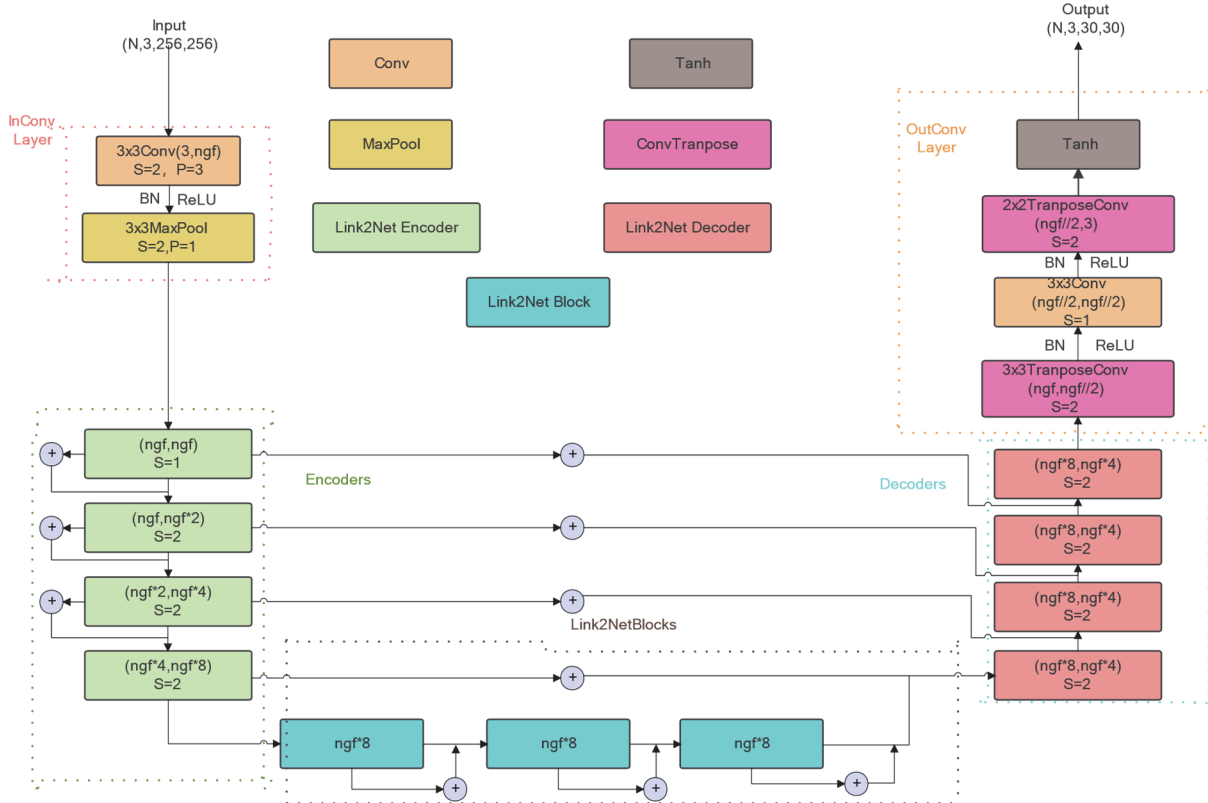


图 3.3.4 Link2Net 结构示意图

Figure 3.3.4 Schematic diagram of Link2Net structure

3.4 本章小结

本章首先介绍了数据的增强方式。根据 ECT 图像一般为中心对称图像的特点，选用随机 90 度旋转对数据集进行增强。再介绍了损失函数、生成器、特征提取层设计思路与理论根据；介绍了这样改良预料中的结果：更好的模型精度，更低的逻辑推理运算量。最后，用图与文字的形式介绍了模型的结构，详细介绍了编码器、解码器、特征提取网络与总体网络结构图。

4 试验与结果分析

4.1 试验结果

表 4.4.1 各模型 ECT 成像重建效果对比表

Table 4.4.1 Comparison table of ECT imaging reconstruction effects of each model

Ground	ECT 传统算法	Pix2Pix	ResNet9	LinkNet	Link2Net	Link2Net
Truth	重建图像	UNet	no block			

在控制了初始学习率、学习率调整策略、学习轮次、数据集、数据集增强方法、损失函数的情况下，ECT 重建效果图如上所示。其中前三张图为仿真常见的油-水单、多泡流，后三张图为仿真固-液多相流。显然，Link2Net 的辨识度相较于其他网络有较大提升。

4.2 测试结果评价

在控制了初始学习率($2e-4$)、学习率调整策略(cosine)、学习轮次(200epoch)、数据集(由 LBP、Tikhonov、Landweber 产生的图像)、数据集数量(2700)、数据集增强方法(随机旋转)、损失函数(Discriminator 与多种评价标准的加权和)的情况下。

下表显示了在 300 张测试集的客观标准评价表。客观评价标准包括 SSIM(结构相似性), MS-SSIM(多尺度结构相似性), MAE(平均绝对误差)与 PSNR(峰值信噪比)

表 4.2.1 各模型 ECT 成像重建效果客观标准评价对比表

Table 4.2.1 Comparison table of objective standard evaluation of ECT imaging reconstruction effect of each model

生成器	模型参数量 (M)	推理运算量 (GFlops)	SSIM (1e-2)	MSSSIM (1e-2)	MAE (1e-2)	PSNR (dB)
传统算法图像	-	-	69.85	50.07	20.25	12.12
UNet	54.41	18.15	92.00	81.66	3.20	16.48
ResNet9	7.84	42.40	91.99	85.34	2.94	16.97
LinkNet	11.5	3.03	94.18	91.40	1.75	19.34
Link2Net_8s	2.3	1.22	88.73	90.19	3.24	18.73
Link2Net_8s_2block	13.3	1.95	94.20	91.41	1.73	19.44
Link2Net_4s_6block	46.5	4.15	94.42	91.97	1.65	19.72
Link2Net_8s_6block	35.3	3.40	94.45	91.96	1.63	19.81

注 1: SSIM, MS-SSIM 的值越接近 1, MAE 的值越接近 0, PSNR 越大, 表示生成图片质量越高

注 2: Link2Net_[]s_[]block 分别表示网络的规模(scale)与特征提取网络模块数(block)

从表 4.2.1 中可以看出, 基于 Link2Net 的 ECT 重建算法模型对比 UNet, ResNet9, LinkNet 均有明显提升。其中, Link2Net_8s_2block 模型在大幅降低推理运算量(1.95GFlops)的同时达到了比原有网络更加的效果。Link2Net_4s_6block 与 Link2Net_8s_6block 验证了在增大 Link2Net 编码器规模(scale)与特征提取网络模块数(block)对于提升模型效果的正相关性。

本文中采用的计算加速卡为单张 NVIDIA TESLA P40, 在运行 Link2Net_8s_2block 与 Link2Net_8s_6block 时分别能达到 164 帧/秒与 212 帧/秒的运行速率, 能够达到实时性的要求。

4.3 本章小结

首先本章展示了测试集中的部分实验结果。这些实验结果分别模拟了实际情况中油-水单/多泡流, 后三张图为仿真固-液多相流。随后, 引入 SSIM, MS-SSIM, MAE, PSNR 等指标对几种网络进行横向比较, 证明 Link2Net 网络的优越性。最后, 提供了推理时间的数据, 证明了在工业实践情况下, 将本模型作为实时性图像重建的可行性。

5 总结与展望

5.1 总结

ECT 借助其非侵入式与低成本的特性,对于现代工业与医学检测领域有重要意义。ECT 的理论研究相对成熟,但是由于传统方式重建的图像较为模糊,图像精度与重建速度难以满足快速发展的工业。因此,研究具有更高精度,更容易辨认的重建图像算法,具有很高的现实意义。

本文结合传统重建方法与对抗生成网络,融合 LinkNet、Res2Net,提升了模型的精度与推理速度。

本文主要内容总结如下:

1.对 ECT 系统发展情况进行梳理,对现有的 ET 图像重建算法进行总结与分析:当前算法存在重建效果差,成像速度慢的问题。并提出基于现有算法的二次重建的 ECT 重建算法。

2. 介绍 GAN, Pix2Pix,LinkNet,ResNet,Res2Net,ESNet 的模型构成与思想。结合优点设计并开发重建效果好、速度快的 Link2Net 模型。并结合多项指标,调整损失函数。

3. 通过调整 Link2Net 编码器的规模,特征提取模块数量,多次试验。控制变量的与已有网络进行比对,验证了模型的有效性。

5.2 展望

本文尚有不少未完全考虑的部分,待改进方面如下:

1.由于模型训练时间长,仅探究增加 Link2Net 编码器的规模,模块数在一定范围内与训练效果的正相关性。在不断增加规模与模块数的情况下,模型理论上将存在一个精度瓶颈。需要调整参数,大量试验来得到相关数据。

2.完全脱离硬件对 ECT 进行二次成像具有泛化性强的优点,但也同时会降低针对某一特定仪器或某一特定初次重建算法的模型精度。在实际运用中,可以通过新建数据集进行加强训练的方式来增强模型精度。

参考文献

- [1] 马平,周晓宁,田沛.过程层析成像技术的发展及应用[J].化工自动化及仪表,2009,36(01):1-5.
- [2] Roger C. Waterfall, Ruhua He, Christopher M. Beck Visualizing combustion using electrical impedance tomography[J]. Chemical Engineering Science, 1997,52(13);2129-2138
- [3] Alme K J, Mylvaganam S. Electrical capacitance tomography—sensor models, design, simulations, and experimental verification[J]. IEEE Sensors Journal, 2006, 6(5): 1256-1266.
- [4] 宋亚杰. 电容层析成像图像重建算法及流型辨识研究[D]. 保定:华北电力大学, 2019.
- [5] 林甲楠. 电容层析成像图像重建数学理论及算法研究[D].哈尔滨理工大学,2015.
- [6] 王化祥,唐磊,闫勇. 电容层析成像图像重建的总变差正则化算法[J].仪器仪表学报,2007(11):2014-2018.
- [7] 高宝庆. 基于迭代法的电容层析成像图像重建算法[D].哈尔滨理工大学,2010.
- [8] Li J , Yang X , Wang Y , et al. An Image Reconstruction Algorithm Based on RBF Neural Network for Electrical Capacitance Tomography[C]// Electromagnetic Field Problems and Applications (ICEF), 2012 Sixth International Conference on. IEEE, 2012.
- [9] ZHANG J, PENG L H. An autoencoder - based image reconstruction for electrical capacitance tomography[J]. IEEE Sensors Journal,2018,18(13):5464-5474.
- [10] A Multi-Level Reconstruction Algorithm for Electrical Capacitance Tomography Based on Modular Deep Neural Networks
- [11] Darma P N, Baidillah M R, Sifuna M W, et al. Improvement of image reconstruction in electrical capacitance tomography (ECT) by sectorial sensitivity matrix using a K-means clustering algorithm[J]. Measurement Science and Technology, 2019, 30(7): 075402.
- [12] 鞠冲. 基于生成对抗神经网络的 ECT 图像重建算法研究[D].辽宁大学,2020.
- [13] Deabes W, Khayyat K M J. Image reconstruction in electrical capacitance tomography based on deep neural networks[J]. IEEE Sensors Journal, 2021, 21(22): 25818-25830.
- [14] 韩旭. 基于 GAN 的 ECT/ERT 双模态传感器数据融合算法研究[D].辽宁大学,2022.
- [15] 张悦,赵哲,赵国桦等.基于改进 SRGAN 网络的 CT 图像增强应用研究[J].微电子学与计算机,2022,39(11):27-36.
- [16] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.
- [17] Isola P, Zhu J Y, Zhou T, et al. Image-to-image translation with conditional adversarial

- networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1125-1134.
- [18] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [19] Chaurasia A, Culurciello E. Linknet: Exploiting encoder representations for efficient semantic segmentation[C]//2017 IEEE visual communications and image processing (VCIP). IEEE, 2017: 1-4.
- [20] Gao S H, Cheng M M, Zhao K, et al. Res2net: A new multi-scale backbone architecture[J]. IEEE transactions on pattern analysis and machine intelligence, 2019, 43(2): 652-662.
- [21] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.